

面向稀疏概念覆盖的概念可达性认知诊断

摘要

认知诊断旨在根据学生历史作答记录估计其对知识概念的掌握状态。现有神经认知诊断与图认知诊断模型通常依赖学生-题目响应日志和题目-概念矩阵进行预测，但在真实学习平台中，学生历史并不总是直接覆盖当前题目涉及的目标概念。当目标概念缺少历史覆盖时，模型需要从学生已练习概念和训练日志中的概念关系中寻找可用支撑。为此，本文提出概念可达图（Concept Reachability Graph, CRG）和学习者条件化可达性过滤器（Learner-Conditioned Reachability Filter, LCRF）。CRG 基于训练日志中的题内概念共现、序列转移、自保持和可靠性统计构造全局概念路线图，并为目标概念给出固定支持集；LCRF 在该支持集内根据学生掌握度、近期表现、路线邻居状态和历史计数重排后验路线权重。三个真实数据集上的实验表明，CRG 能够恢复训练日志中的概念转移，并在 `assist_09` 和 `junyi` 上从学生历史概念检索当前查询概念。进一步的覆盖条件预测、支持集扰动和学习者状态替换实验显示，CRG-LCRF 的收益主要出现在目标概念直接覆盖不足但存在可达路线的场景中。

关键词：认知诊断；稀疏概念覆盖；概念可达图；概念路线；学习者条件化过滤

1. 引言

认知诊断（Cognitive Diagnosis, CD）是智能教育系统中的基础任务，目标是根据学生历史作答记录推断学生对知识概念的掌握状态。诊断结果可以服务于个性化练习推荐、补救学习、学习路径规划和自适应测试。近年来，神经认知诊断和图认知诊断模型通过更复杂的学生-题目交互函数、概念图传播或学生-题目-概念异构图建模提升了预测性能。然而，这些方法通常默认学生历史记录能够为当前目标概念提供直接支撑。

在真实学习平台中，这一条件并不总是成立。学生不会完整练习所有知识点，当前题目涉及的目标概念可能从未出现在该学生历史中，或者只在极少量历史记录中出现。此时，模型如果仅依赖学生已经作答过的概念维度，就会遇到直接概念覆盖不足的问题：目标概念需要被预测，但学生历史中没有对应的直接观测。

这一问题不同于一般意义上的短历史或冷启动。关键不只是学生历史长度是否短，而是目标概念能否通过训练日志中的概念关系与学生历史概念连接起来。即使一道题只对应一个知识点，训练序列中仍可能包含从历史概念到目标概念的经验性学习路线。相反，如果只依赖题内多概念共现，那么在 `junyi` 这类单概念题占比极高的数据集中，概念关系图会退化为近似空图。因此，本文将题内概念共现、序列转移、自保持和可靠性统计共同用于构造概念路线。

基于这一观察，本文提出 CRG/LCRF 两阶段框架。CRG 首先构造全局概念路线图，并为每个目标概念给出固定支持集；LCRF 随后在该固定支持集上建模学习者条件化后验路线分布，用于判断哪些候选路线更适合当前学生。两者分别对应全局路线构造和局部学生过滤。

如图 1 所示，左侧学生历史包含已观测过的概念及有限正确、错误、未观测记录，目标概念 c 需要被预测，但没有出现在该学生的历史概念集合中。中间的 CRG 利用训练日志中的经验路线将历史概念连接到目标概念，其中 `sequence transition` 表示日志中观察到的学习顺序，而非严格先修关系。右侧的 LCRF 在 CRG 给出的固定支持集内进行个性化后验重排，使后验权重随学生状态变化而变化。

本文贡献如下：

1. 提出直接概念覆盖不足视角，将该场景下的认知诊断转化为概念路线构造与固定支持集内过滤问题。
2. 设计 CRG，从题内共现、序列转移、自保持和可靠性统计中构造全局概念路线图，并为目标概念给出固定支持集。
3. 设计 LCRF，根据学生掌握度、近期表现、路线邻居掌握度、准备度差距和历史计数，在同一 CRG 支持集内重排后验路线权重。
4. 在三个真实数据集上，通过路线检索、覆盖条件预测、支持集扰动、学习者状态替换和同题个案分析模型行为。




图 1：直接概念覆盖不足与支持约束个性化。学生历史只覆盖少量历史概念，而当前目标概念未被直接观测。CRG 利用训练日志中的题内共现、序列转移、自保持和可靠性统计构造可达支持集；LCRF 在相同支持集内根据学生状态重排后验路线权重。

2. 相关工作

2.1 认知诊断模型

传统认知诊断模型通常建立在心理测量理论之上，例如 IRT、MIRT 和 DINA。它们通过预设的交互函数描述学生能力、题目难度和作答结果之间的关系，具有较强解释性，但表达能力有限。神经认知诊断模型进一步使用神经网络建模复杂的学生-题目交互，使模型能够从大规模作答数据中学习非线性诊断函数。典型方法通常以学生嵌入、题目嵌入和概念嵌入作为输入，通过预测学生在题目上的作答结果来优化模型。NCDM、KaNCD 等方法将学生、题目和概念表示映射到连续空间中，RCD、SCD、ORCDF 等图式方法进一步利用学生-题目-概念关系提升表示能力。

这些方法主要从学生-题目响应中估计掌握状态，但较少显式区分目标概念是否已被学生历史直接覆盖。若目标概念缺少历史观测，模型可能更多依赖 ID embedding 或全局统计模式。本文关注的不是新学生或新题目完全未见的冷启动，而是目标概念与学生历史概念之间的连接问题。

2.2 图认知诊断与概念关系建模

图认知诊断模型通过学生-题目图、题目-概念图或异构图传播建模高阶关系。相关工作表明，图结构可以提升学生和题目的表示能力，并有助于建模概念、题目和学生之间的依赖关系。与此同时，图结构也需要明确边的来源、方向和作用方式。已有研究从学生-题目边的异质性、不确定性和噪声角度分析图传播问题；本文则从目标概念缺少直接历史覆盖时的概念路线来源出发，构造由训练日志关系约束的概念可达图，并在固定支持集内进行学习者条件化过滤。

与 RCD、SCD、ORCDF 等直接在学生-题目或异构图上传播表示的方法不同，CRG 面向概念层面的路线构造，重点在于为目标概念选择可达的候选概念集合。与关注学生-题目边不确定性的 ISG-CD 不同，本文不改变学生-题目图的传播边，而是从题内共现、序列转移和自保持中构造概念间路线。

2.3 稀疏概念覆盖与可靠诊断

现有研究已从冷启动学生/题目、非随机缺失响应、噪声交互和不可靠图边等角度研究认知诊断中的数据不足问题。KCD、DFCD 和 LRCD 等方法利用文本语义或语言表示缓解冷启动、开放环境或跨域诊断问题；DBCD 从非随机缺失与反事实建模角度分析学生选择性作答带来的偏差；NCDLA 从噪声与低秩结构角度研究图认知诊断的鲁棒性。与这些问题不同，本文关注目标概念层面的覆盖不足：学生可能拥有一定长度的历史作答记录，但这些记录并不直接包含当前题目所需概念。因此，模型需要判断目标概念能否由历史概念通过训练日志中的概念路线获得支持，并进一步判断该支持集是否适合当前学生。CRG 和 LCRF 分别对应这两个层次：前者构造全局可达支持集，后者在固定支持集内建模学习者条件化后验路线分布。

3. 问题定义：直接概念覆盖不足

设学生、题目和概念集合分别为 $\mathcal{U}$ 、 $\mathcal{E}$ 和 $\mathcal{C}$ 。题目-概念矩阵 Q 描述每道题涉及的概念，学生作答日志 $\mathcal{R}$ 由学生、题目和二值作答结果组成。给定学生 u 在时间 t 的 query exercise，记 $H_{u,t}$ 为该学生此前作答历史中出现过的概念集合。

本文使用两个诊断量刻画 query 的概念覆盖条件。直接覆盖 $D_{u,t}(c)$ 表示目标概念 c 是否已经出现在 $H_{u,t}$ 中；CRG reachability 表示目标概念是否能在 CRG 给出的固定支持集 $S_A(c)$ 中获得候选路线。二者用于数据现象分析和模型解释，而不是限制预测任务本身；模型仍在完整作答样本上训练与评估。概念可达图由训练阶段可观测的概念关系估计，并在验证与测试阶段保持固定。

4. 直接概念覆盖不足现象

表 1 展示三个数据集的概念可达性画像。三组数据呈现不同条件：有的数据包含少量题内共现，有的数据几乎完全依赖序列路线，有的数据在较长学生历史下更适合分析支持集敏感性。

表 1：三个数据集的概念可达性画像


数据集	单概念比例	多概念比例	sequence				历史长度中位数
			item edge density	edge density	direct-unseen rate	bridge-only rate	
assist_09	82.8%	17.2%	0.9%	64.3%	3.1%	3.1%	41
junyi	100.0%	0.0%	0.0%	25.2%	100.0%	99.97%	25
assist_17	78.3%	21.7%	6.2%	76.3%	2.8%	2.8%	148

从表 1 可以看出，三组数据集均呈现不同形式的直接概念覆盖不足。junyi 没有题内概念共现，但 direct-unseen rate 与 bridge-only rate 均很高，适合检验序列路线的可达支持。assist_09 和 assist_17 更接近常规 benchmark 场景，少量题内共现与较强序列路线共同存在。上述差异说明，概念可达性不能仅由题内多概念共现刻画，还需要训练日志中的经验学习路线提供补充。

5. 方法

5.1 框架总览

本文框架包括两个递进组件：CRG 和 LCRF。CRG 负责构造全局概念路线图，用于形成固定支持集；LCRF 负责在该支持集上进行学习者条件化后验过滤。整体流程为：



CRG (2) is the global auditable route constructor from train-only evidence. LCRF (4) does not add new support; it only reweights the posterior within the CRG-defined support.

图 2: CRG/LCRF 机制架构。CRG 从训练阶段证据构造全局概念路线图，并为目标概念定义固定支持集；LCRF 只在该支持集内根据学生状态产生后验路线分布，最终进入诊断预测头。

$$\text{training route statistics} \rightarrow A_{\text{CRG}} \rightarrow S_A(c) \rightarrow P_{u,t}(k|c) \rightarrow \hat{r}_{u,e}.$$

其中 $S_A(c)$ 是目标概念 c 的固定 CRG 支持集， $P_{u,t}(k|c)$ 是 LCRF 产生的学生条件化后验路线分布。

图 2 展示了 CRG/LCRF 的整体机制路径。CRG 只从训练阶段可观测证据中构造概念路线图，证据包括题内共现、序列转移、自保持以及 source/receiver reliability。随后，CRG 为当前 query concept 给出固定支持集 $S_A(c)$ 。LCRF 不参与支持集构造，也不扩展支持集，而是根据 query mastery、recent mastery、route-neighbor mastery、readiness gap 和 support count 等学生状态信号，对同一支持集内的后验路线权重进行个性化重排。

5.2 概念可达图 CRG

CRG 为 query concept c 和候选 support concept k 估计全局路线分数。路线统计包括题内共现、经验序列转移、自保持，以及 source/receiver reliability。设归一化后的路线特征为：

$$\phi_{c,k} = [\tilde{M}_{c,k}^{\text{item}}, \tilde{M}_{c,k}^{\text{seq}}, \mathbb{I}(c=k), \text{rel}_c^{\text{src}}, \text{rel}_k^{\text{rec}}], \quad s_{c,k} = \mathbf{w}^\top \phi_{c,k}.$$

其中 $\tilde{M}^{\text{item}}$ 表示题内共现关系， $\tilde{M}^{\text{seq}}$ 表示训练日志中的经验学习路线；本文不将 sequence transition 解释为严格先修关系或因果依赖。CRG 首先收集具有训练阶段关系的候选集合 $\mathcal{N}(c)$ ，并在该候选集合上进行归一化：

$$A_{\text{CRG}}(c, k) = \text{softmax}_{k \in \mathcal{N}(c)} \left(\frac{s_{c,k}}{\tau} \right).$$

最终，CRG 为每个 query concept 选择固定支持集：

$$S_A(c) = \text{TopK}_{k \in \mathcal{N}(c)} A_{\text{CRG}}(c, k).$$

因此, A_{CRG} 是由训练日志关系估计得到的全局概念路线图, $S_A(c)$ 是后续 LCRF 可使用的固定支持集。

5.3 学习者条件化可达性过滤器 LCRF

CRG 给出全局支持集, 但同一条路线对不同学生不一定同等适用。LCRF 在 $S_A(c)$ 内计算学生条件化后验:

$$P_{u,t}(k|c) = \text{softmax}_{k \in S_A(c)} [\log A_{\text{CRG}}(c, k) + f_\theta(u, t, c, k)].$$

其中 $f_{\theta}(u, t, c, k)$ 由 query mastery、recent mastery、route-neighbor mastery、readiness gap 和 support count 等学生状态信号计算。由于 softmax 被限制在 $S_A(c)$ 内, LCRF 只改变 CRG 候选路线上的后验权重。预测时, 后验路线分布可用于聚合路线邻居掌握度:

$$\tilde{m}_{u,t}(c) = (1 - \gamma)m_{u,t}(c) + \gamma \sum_{k \in S_A(c)} P_{u,t}(k|c)m_{u,t}(k).$$

最终，融合路线邻居后的掌握表示被送入诊断预测头得到作答概率 $\hat{r}_{u,e}$ 。模型使用训练作答上的二分类交叉熵进行优化。

6. 实验

本节采用“主图展示趋势、完整数值进入附录”的方式组织实验。实验先比较覆盖不足子场景中的预测变化，再给出模块消融，随后分析 CRG 的路线与支持集作用，以及 LCRF 的学习者条件化过滤行为。

Figure 3. Mechanism evidence chain.




图 3: 机制实验证据链。实验先确认概念证据缺口现象, 再验证 CRG 能否检索概念路线, 随后通过支持集扰动、学习者状态替换和 same-query case 分析 CRG/LCRF 的模型行为。

图 3 给出了实验组织方式。本文不把所有数据集解释为同一种强证据, 而是沿着“数据现象—路线检索—支持集扰动—学习者状态替换—同题个案”的顺序展开。CRG 主要通过路线检索和支持集扰动来分析, LCRF 主要通过学习者状态替换与 same-query posterior case 来分析。

6.1 实验设置

实验使用三个数据集：assist_09、junyi 和 assist_17。它们分别覆盖混合概念场景、单概念且强 bridge-only 场景，以及较长学生历史下的支持集敏感性场景。所有数据集均使用既定 train/validation/test split；CRG 由训练阶段可观测关系估计，并在验证和测试阶段保持固定。评价指标包括 AUC、ACC、RMSE 和 BCE，其中 AUC 作为主要预测指标，BCE 用于观察覆盖条件子场景中的概率预测变化。

覆盖条件预测实验使用已有 sample-level prediction 聚合得到，不需要重训模型。本文将 assist_09 的 direct-unseen-bridgeable 子场景、assist_17 的 high-route / weak-direct 子场景作为主要预测分析对象；junyi 主要用于检验无题内共现条件下的路线可达性。

6.2 覆盖条件预测

History-to-query retrieval 说明 CRG 可以在部分数据集上找到从历史概念到目标概念的路线。图 4 展示了两类路线检索结果：左侧评估给定学生历史概念集合时，训练日志路线能否检索当前 query concept；右侧评估 CRG 是否能够恢复全局层面的留出概念转移。assist_09 和 junyi 的 history-to-query 面板显示 seq-only 或 fused CRG 明显高于 random；held-out transition 面板进一步显示 Best CRG 在三个数据集上均优于 self-only 与 random controls。




图 4: CRG 路线检索结果。左侧为从学生历史概念检索当前 query concept，右侧为全局留出概念转移检索。

进一步地，本节分析这些路线是否会在预测中带来收益。与全体样本平均结果相比，coverage-conditioned prediction 更关注目标概念直接覆盖不足、但存在可达路线的子场景。

图 5 将完整数值表压缩为覆盖条件子场景的 forest plot。assist_09 的 direct-unseen-bridgeable、weak-direct 与 high-route 子场景中，Full 相对 no_CRG 和 no_LCRF 均保持更低 BCE，其中 direct-unseen-bridgeable 子场景的 BCE 差值分别为 0.0219 和 0.0382。assist_17 的 high-route 与 weak-direct 子场景中，Full 相比 no_CRG 的 AUC 提升约为 0.0151，BCE 差值也保持为正；相比 no_LCRF 时，AUC 差异较小，但 BCE 仍有改善。junyi 的预测层差异较小，因此本文更多用它说明无题内共现条件下的路线可达性。完整 coverage-conditioned 数值表见附录 B。

6.3 模块消融

表 2 展示三个数据集上的模块消融结果。full 表示 CRG+LCRF 完整模型；no_CRG 移除全局路线图；no_LCRF 保留 CRG 但移除学习者条件化过滤。

表 2: 三个数据集上的模块消融结果




图 5: 覆盖条件预测结果。点表示 Full 相对消融变体的提升, 横线为 500 次 test-sample bootstrap 的 95% 置信区间; 正向 ΔBCE 表示 Full 的 BCE 更低。

数据集	模型变体	AUC	ACC	RMSE	相对 Full 的 AUC 下降
assist_09	full	0.7783	0.7407	0.4178	0.0000
assist_09	no_CRG	0.7671	0.7320	0.4222	0.0112
assist_09	no_LCRF	0.7634	0.7309	0.4247	0.0149
junyi	full	0.8291	0.7688	0.4008	0.0000
junyi	no_CRG	0.8278	0.7691	0.4011	0.0013
junyi	no_LCRF	0.8286	0.7701	0.3994	0.0005
assist_17	full	0.7847	0.7151	0.4321	0.0000
assist_17	no_CRG	0.7647	0.6973	0.4413	0.0200
assist_17	no_LCRF	0.7829	0.7132	0.4359	0.0018

完整模型在 assist_09 和 assist_17 上取得最高 AUC，相比 no_CRG 分别提升 1.12% 和 2.00%。移除 LCRF 在 assist_09 上带来更明显下降，而在 junyi 与 assist_17 的直接模块删除设置下影响较小。该结果说明，CRG 提供主要的可达支持信号；LCRF 的作用需要结合第 6.5 节的学习者状态替换实验进一步观察。

6.4 路线与支持集分析

路线检索评估 CRG 的恢复能力；支持集扰动进一步分析预测对支持集的敏感性。我们在不重训的情况下替换或破坏 CRG 支持集，并观察预测性能变化。图 6 中包含 evidence support replacement、degree-matched random support、sequence-shuffled support 和 self-only fallback 等对照。

图 6 表明，替换 CRG 支持集会改变模型预测表现。assist_17 中 evidence support replacement 明显强于 degree-random，尤其 AUC drop gap 更突出，说明模型对 CRG routes 具有较强依赖。assist_09 中 evidence replacement 与 degree-random 接近，体现出模型对候选支持空间的依赖。junyi 的 AUC 变化较小，但 BCE increase 显示支持集扰动会影响概率校准。完整支持集扰动数值见附录 B。

6.5 学习者条件化过滤

本节分析 LCRF 对学习者状态的使用方式。我们使用三种变体：no_filter 表示移除 LCRF；mean_state 用群体平均学生状态替代真实状态；shuffle_state 打乱学生状态。

图 7 区分了模块移除和状态替换两类干预。no_filter 反映移除 LCRF 后的整体预测变化；mean_state 和 shuffle_state 进一步检验真实学习者状态是否可以由群体平均状态或错配状态替代。assist_09 和 assist_17 在 mean/shuffle 干预下出现明显下降，说明 LCRF 的后验路线分布依赖学习者状态。junyi 中变化较小，更接近 CRG-dominant 的数据集类型。

为了观察局部行为，本文固定同一个 query concept 和相同 CRG 支持集，比较不同学生得到的后验路线分布。assist_17 的主 case 为 assist_17_Q14_S25。该 case 中所有学生共享相同支持集，support size 为 25；候选统计显示 mean pairwise L1 最高可达到 0.801，JS 为 0.129。two-student case 中，S1 与 S7 的后验路线差异明显。

图 8 展示了 LCRF 的个性化过滤行为：在同一 query、同一 CRG 支持集下，不同学生会得到不同后验路线分布。S1 的后验权重更集中于 C7，而 S7 更强调 C12；这说明 LCRF 并非为所有学生复用同一全局路线分布，而是在固定支持集内根据学习者状态调整路线权重。完整 same-query posterior 行表见附录 B。

7. 讨论

训练路线有助于连接未覆盖目标概念。当目标概念缺少直接历史覆盖时，模型需要从训练日志中寻找可用概念路线。全局 held-out transition retrieval 表明 CRG 能恢复训练日志中的概念转移；history-to-query retrieval 进一步显示，assist_09 和 junyi 上的序列路线能够从学生历史概念检索当前查询概念。尤其在 junyi 中，题内共现完全缺失，sequence route 仍然能提供可达支持。





图 6: CRG 支持集扰动结果。图中比较不同支持集替换或扰动方式下的预测变化。





图 7: LCRF 学习者状态反事实结果。图中比较 no-filter、mean-state 和 shuffle-state 相对完整模型的变化。



The two students share the same query and CRG support; LCRF redirects posterior mass without adding support concepts.

图 8: Same-query posterior case。在同一 query concept 和同一 CRG 支持集下，不同学生获得不同后验路线权重。

预测收益集中在覆盖条件子场景中。全体样本平均指标能够反映模型总体表现，但对直接概念覆盖不足场景的刻画有限。Coverage-conditioned prediction 显示，CRG-LCRF 的收益更集中地出现在 assist_09 的 direct-unseen-bridgeable 样本，以及 assist_17 的 high-route / weak-direct 子组中。junyi 的预测层差异更小，更适合用于说明无题内共现条件下的路线检索和数据现象。

固定支持集过滤将路线构造与个性化分开。CRG 给出的支持集回答“哪些概念可作为候选支持”，而 LCRF 进一步回答“哪些支持更适合当前学生”。学习者状态反事实显示，assist_09 和 assist_17 中真实学生状态被均值化或错配替换后预测显著下降；问题个案进一步展示了同一支持集在不同学生上的后验变化。

直接概念状态仍然是强信号。额外的直接概念状态移除压力测试表明，完整模型对 query concept 的直接历史状态仍然敏感。这一结果与本文目标一致：CRG-LCRF 旨在目标概念直接覆盖不足时提供显式路线补充和固定支持集内过滤，而不是完全替代直接作答信号。

8. 结论

本文提出面向稀疏概念覆盖的 CRG-LCRF 框架。CRG 从训练阶段题内共现、序列转移和自保持关系中构造全局概念路线图，用于连接学生历史概念和当前目标概念；LCRF 在 CRG 固定支持集内，根据学生状态重排后验路线分布，实现局部个性化过滤。

三个数据集上的实验表明，CRG 能有效检索留出的概念转移，并能在 assist_09 和 junyi 上从学生历史概念中检索当前查询概念。Coverage-conditioned prediction 进一步显示，CRG-LCRF 的预测收益主要出现在 assist_09 的 direct-unseen-bridgeable 子场景和 assist_17 的 high-route / weak-direct 子组中。支持集扰动、学习者状态反事实和同题个案分析分别展示了 CRG 支持集对预测的影响以及 LCRF 在固定支持集内的个性化过滤行为。该框架为目标概念缺少直接历史覆盖时的认知诊断提供了一种基于显式概念路线的建模方案。未来工作将进一步扩展 CRG 的高阶概念路线建模，并研究更细粒度的学习者状态来源分解。

附录 A. 直接概念状态移除压力测试

除主文实验外，我们还进行了直接概念状态移除压力测试。该实验通过 buffer-level state mask 移除 query concept 的直接状态信号，观察完整模型在直接概念信息受损时的预测变化。结果显示，完整模型仍然对 query concept 的直接历史状态较为敏感，并未表现出完全替代直接概念信息的能力。

这一压力测试不作为主文的正向结果，而用于界定方法的适用范围：CRG-LCRF 提供的是直接概念覆盖不足时的路线补充和固定支持集内的学生条件化过滤，而不是直接作答信号的替代机制。

附录 B. 完整数值表与复现实验文件

主文将主要趋势整理为图形展示，完整数值保留在结果文件中：

- History-to-query route retrieval: results/main_problem_experiments_20260523/*/main_problem_exp1_history_to_q
- Coverage-conditioned prediction: results/main_problem_experiments_20260523/coverage_conditioned_prediction
- Global held-out transition retrieval: results/crg_lcrf_core3_final_20260520/crg_retrieval/crg_retrieval_full_c
- CRG support perturbation: results/crg_lcrf_core3_final_20260520/crg_support_gap_audit_core3.csv
- LCRF learner-state counterfactual: results/crg_lcrf_core3_final_20260520/lcrf_counterfactual/lcrf_counterfa
- Same-query posterior case: results/crg_lcrf_core3_final_20260520/lcrf_same_query_annotated_core3.csv
- Direct concept evidence removal stress test: results/main_problem_experiments_20260523/direct_evidence_removal_

参考文献